端侧知识库：技术说明

文档与查询均由浏览器 Worker 本地向量化，Node 只提供回环 HTTP 和 seekdb 存储/检索。模型为 Apache-2.0 的 Xenova/all-MiniLM-L6-v2，固定 revision 751bff37182d3f1213fa05d7196b954e230abad9，384 维、mean pooling、L2 归一化；使用发布的 FP32、FP16、q8 ONNX。q8 图包含 INT8/UINT8 权重及 FP32 数据，不等同全部运算均为 INT8。Transformers.js 3.8.1 和 ORT Web 资源固定版本与校验。

自动模式优先 WebGPU/FP16；不可用或初始化/推理失败时使用新的 WASM/q8 Worker，界面显示实际后端。真实自动回退及一文档查询记录见 自动回退证据。seekdb-js 1.4.0 使用嵌入式库，collection 存向量、原文及 metadata，建立 cosine/HNSW 和全文索引；写入后刷新，参数化 SQL 在数据库内完成向量与全文 RRF 融合。不同知识库和请求按状态隔离。运行、数据及模型获取见 README。

对照实验。 2026-11-03，Windows、Edge 156、Intel gen-12lp；20 篇合成开发文档、10 个查询，每查询 3 次，另每模式 2 次预热。标注经复核，非官方 gold。相同模型资源口径下 FP16 相对 FP32 压缩 1.975 倍，q8 相对 FP32 压缩 3.819 倍。完整 原始 JSON 含全部阶段及排名，SHA-256 5133ba07c6afc7b284aa4f09d28f9e0429df10684124c48041b54261b74f1853；实验应用源码版本 f11ab8b26bb740a98af9adac398dafbadcda74f8。

模式	模型字节	Recall@5/nDCG@5	初始化 ms	文档向量化 ms	写入/刷新 ms	DB 查询中位数 ms	首次/后续 ready ms	后续显示 ms
fp32-gpu	91,331,916	1.000/1.000	3195.7	163.1	354.5/415.8	3.02	69.5/27.7	652.2
fp16-gpu	46,242,135	1.000/1.000	1744.5	116.4	169.6/402.1	3.45	53.2/28.8	610.4
fp32-wasm	91,331,916	1.000/1.000	1404.2	1002.5	176.9/403.0	2.77	52.4/41.5	683.3
q8-wasm	23,916,680	1.000/1.000	969.6	689.6	175.0/416.6	3.06	45.7/34.1	2007.4

表中文档向量化耗时为实际导入所用的 batch 4 第 3 轮，而非三轮中位数。批处理对照在同一模式下对 20 篇文档各重复 3 轮，以 batch 1/4 墙钟中位数计算：FP32 GPU 为 2.173 倍（64.0→139.2 篇/秒），FP16 GPU 为 2.717 倍（66.6→181.0），FP32 WASM 为 1.010 倍（20.3→20.5），q8 WASM 为 0.990 倍（29.4→29.1）；后两者未见明显收益。

2026-10-31 的独立资源获取记录中，FP32、FP16、q8 权重串行下载分别耗时 19.141、11.429、6.207 秒；计时含 HTTPS、重定向、读写和落盘，不含共享配置与运行时包，详见脱敏摘要。这不是 11 月 3 日浏览器实验的同次冷启动，不能与下述初始化耗时相加。

初始化包含缓存/文件获取和会话建立；首次为新 Worker、未清除浏览器/模型/设备缓存。文档向量化为 20 篇共享批次；后续为每题第 2、3 次中位数，ready 包含查询向量化及数据库往返。显示计时为 DOM 更新及两次动画帧机会，不是物理呈现时刻；本次显示值较高，浏览器调度及前台条件未单独校准。完整样本与 batch1/4 各三轮均保留于原始记录，不能据小规模开发集推断正式得分。